

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

POROVNANIE NIEKOĽKÝCH TYPOV
REKURENTNÝCH SIETÍ Z HĽADISKA HĽBKY
PAMÄTE
DIPLOMOVÁ PRÁCA

2019

JAROSLAV IŠTOK

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

POROVNANIE NIEKOĽKÝCH TYPOV
REKURENTNÝCH SIETÍ Z HĽADISKA HĽBKY
PAMÄTE
DIPLOMOVÁ PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: 2511 Aplikovaná informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: školiteľ

Bratislava, 2019
Jaroslav Ištók



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Jaroslav Ištók
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: aplikovaná informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Porovnanie niekoľkých typov rekurentných sietí z hľadiska hĺbky pamäte
Memory span in recurrent neural network types: a comparison

Anotácia: Cieľom práce je preskúmať a porovnať vlastnosti niektorých typov rekurentných samoorganizujúcich sa máp (MSOM, RecSOM a ich modifikácií) s Elmanovou jednoduchou rekurentnou sieťou (SRN), najmä z hľadiska hĺbky a kapacity pamäte. Práca zahŕňa implementáciu, výpočtové simulácie a analýzu vrátane preskúmania priestoru parametrov.

Literatúra: Elman, J. (1990). Finding structure in time. Cognitive Science, 14, 179-211.
Strickert, M. & Hammer, B. (2005). Merge SOM for temporal data. Neurocomputing, 64, 39-71.

Vedúci: doc. RNDr. Martin Takáč, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: prof. Ing. Igor Farkaš, Dr.
Dátum zadania: 05.10.2017

Dátum schválenia: 12.10.2017
prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Čestné vyhlásenie

Abstrakt

Abstrakt - obsah

Kľúčové slová: rekurentné neurónové siete, hĺbka pamäte

Abstract

Abstract

Keywords: neural net, machine learning, memory span

Obsah

1	Úvod	1
1.1	Motivácia	1
1.2	Prehľad literatúry a úvod do problematiky	1
1.2.1	Samoorganizujúce sa mapy	1
1.2.2	Trénovanie	2
1.2.3	Využitie SOM	4
1.3	Štruktúra ďalšej práce	5
1.4	Typy neurónových sietí	5
1.5	Elmanova sieť a backpropagácia v čase	5
1.6	Meranie hĺbky pamäte samorganizujúcich sa máp	5
2	Návrh riešenia	7
3	Implementácia	8
4	Experiment	9
5	Vyhodnotenie a výsledky experimentu	10
6	Záver	11
6.1	Limity a nedostatky riešenia	11
6.2	Možnosti ďalšej práce	11
	Bibliography	11

Zoznam obrázkov

1.1	Neúplne rozvinutá sieť	3
1.2	Motýlí efekt	4
1.3	Pinch effect	4

Kapitola 1

Úvod

1.1 Motivácia

Väčšina modelov v strojovom učení predikuje alebo klasifikuje iba na základe aktuálneho vstupu pričom neberie do úvahy predchádzajúce vstupy. Existujú však úlohy pri ktorých potrebujeme brať do úvahy aj predchádzajúce stavy z minulých vstupov, čo nazývame kontext. Predstavme si napríklad, že chceme sieť naučiť predikovať ďalšie písmeno v slove. Ako príklad si vezmime slovo "java". Trénovanie nerekurentnej siete by prebiehalo nasledujúcim spôsobom: sieti dám písmeno "j" a poviem, že očakávam "ä" takto pokračujem ďalej. Problém nastane pri písmene "v", kde opäť očakávam "ä", ale sieť je už naučená, že písmeno "ä" nasleduje po "j". Je zrejmé, že na vyriešenie tohto problému potrebujem brať do úvahy aj nejaký historický kontext, teda stavy siete z predchádzajúcich krokov. Takýto druh neurónovej siete sa nazýva rekurentná neurónová sieť.

V našej diplomovej práci budeme skúmať hĺbku pamäte rôznych typov neurónových sietí.

1.2 Prehľad literatúry a úvod do problematiky

1.2.1 Samoorganizujúce sa mapy

Je to typ neurónovej siete, v ktorej sú jednotlivé neuróny usporiadané v štvorcovej mriežke. Samoorganizujúce sa mapy (ďalej iba SOM) sú trénované bez učiteľa, čiže váhy jednotlivých neurónov sú upravované iba na základe dát z trénovacej množiny. Čo je zaujímavé na spôsobe trénovania SOM je, že je veľmi podobný učeniu neurónov v mozgovej kôre živočíchov.

Špeciálnou vlastnosťou SOM je, že po natrénovaní zobrazí trénovaciu množinu so zachovanou topológiou. To znamená, že blízke (podobné) vstupy aktivujú blízke ne-

uróny v sieti. Vzdialenosť dvoch neurónov je ich euklidovská vzdialenosť v mriežke. Takéto topologické zobrazenie dát sa vyskytuje aj v biologických neurónových sieťach.

1.2.2 Trénovanie

Trénovanie SOM je založené na tzv. Hebbovom pravidle učenia, ktoré znie nasledovne: Keď má axón bunky A excitačný účinok na bunku B, a opakovane sa zúčastňuje na jej aktivácii, v jednej alebo v oboch bunkách prebehne určitý rastový proces alebo metabolická zmena, takže účinnosť bunky A ako jednej z buniek, ktoré aktivujú B, vzrastie. Proces trénovania SOM je zložený z dvoch častí:

- hľadanie víťaza
- adaptácia váh neurónov

Na začiatku su váhy medzi vstupom a neurónmi v mriežke inicializujú na náhodné hodnoty z určitého intervalu. V každom kroku trénovania nájdeme najskôr víťazný neurón pre daný vstup. Postupne počítam euklidovské vzdialenosti vstupu od váhového vektora jednotlivých neurónov. Víťazom je neurón, ktorý je najbližšie k vstupu (má najkratšiu vzdialenosť).

$$i^* = \operatorname{argmin}_i ||x - w_i|| \quad (1.1)$$

Druhým krokom je adaptácia váh víťazného neurónu a jeho okolia. Pravidlo pre zmenu váh neurónov:

$$w_i(t+1) = w_i(t) + \alpha(t)h(i^*, i)([x(t) - w_i(t)]) \quad (1.2)$$

Váhové vektory víťazného neurónu a jeho topologických susedov sa posúvajú smerom k aktuálnemu vstupu. $\alpha(t)$ predstavuje rýchlosť učenia, ktorá sa môže klesať v čase alebo môže zostať konštantná. Na funkcii, ktorá je použitá pre α v praxi veľmi nezáleží, mala by to byť nejaká monotónne klesajúca funkcia (napríklad exponenciálna funkcia). $h(i^*, i)$ je funkcia okolia (tzv. excitačná funkcia), ktorá definuje koľko neurónov v okolí víťaza bude trénovaných a do akej miery. Inými slovami, excitačná funkcia definuje rozsah kooperácie medzi neurónmi. Používajú sa najčastejšie 2 typy okolia:

- pravouhlé(štvorcové) okolie

$$N(i^*, i) = \begin{cases} 1 & \text{ak } d_M(i^*, i) \leq \lambda(t) \\ 0 & \text{inak} \end{cases}$$

$d_M(i^*, i)$ je Manhattanovská vzdialenosť (L1 norma) medzi neurónmi v mriežke

mapy. Kohonen zistil, že najlepšie výsledky sú dosiahnuté, keď sa veľkosť okolia s časom postupne znižuje.

- gaussovské okolie

$$N(i^*, i) = \exp^{-\frac{d_E^2(i^*, i)}{\lambda^2(t)}} \quad (1.3)$$

$d_E(i^*, i)$ je euklidovská vzdialenosť (L2 norma) neurónov v mriežke. Funkcia $\lambda^2(t)$ sa s časom postupne znižuje až k nule. Táto funkcia slúži na znižovanie okolia víťazného neurónu počas tréningu, čím sa zabezpečí ukončenie učenia.

Pri učení rozlišujeme všeobecne dve fázy:


- usporiadavanie - s časom klesá veľkosť okolia víťazných neurónov
- doladovanie - veľkosť okolia sa zafixuje na nejakej malej hodnote až pokým učenie neskončí.

Kohonen odhadol na základe pokusov, že počet iterácií tréningu, by mal byť rádovo 500-násobok počtu neurónov v sieti. Rovnako sa pozorovaním zistilo, že na fázu doladenia je lepšie ponechať viac času ako na fázu usporiadavania.

Počas tréningu SOM môžu nastať špeciálne situácie:


- Sieť je neúplne rozvinutá - príliš rýchle znižovanie rýchlosti učenia α

Obr. 1.1: Neúplne rozvinutá sieť




- Motýlí efekt - príliš rýchle znižovanie okolia λ

Obr. 1.2: Motýlí efekt



- Pinch efekt - príliš pomalé zmenšovanie okolia λ

Obr. 1.3: Pinch effect



1.2.3 Využitie SOM

- SOM môžeme využiť na mapovanie viacrozmerných dát do 2D - môžeme ju použiť na redukciu dimenzie dát.
- SOM je aj vektorovým kvantifikátorom. Pri vektorovej kvantizácii nahrádzame množinu vektorov vstupných dát menšou množinou vektorov (nazývaných aj prototypy). V SOM sú prototypmi váhové vektory. Toto je možné využiť napríklad na kompresiu dát. Vďaka vektorovej kvantizácii stačí uchovať iba množinu prototypov a informáciu o tom, ktorý vstupný vektor patrí ku ktorému prototypu(centru). Ku každému centru sa potom priradí množina vstupných vektorov,

ktoré ku nemu majú bližšie ako ku akémukoľvek inému centru. (používa sa euklidovská vzdialenosť). Vektorou kvantizáciou teda rozdelíme vstupný priestor na disjunktné oblasti, ktoré tvoria tzv. Voronoiho mozaiku

1.3 Štruktúra ďalšej práce

1.4 Typy neurónových sietí

- elmanova sieť
- recSOM
- mergeSOM

1.5 Elmanova sieť a backpropagácia v čase

Jednoduchú Elmanovu sieť nie je vhodné trénovať pomocou jednoduchého algoritmu spätného šírenia chyby, pretože neberie do úvahy spätné šírenie chybového signálu cez rekurentné prepojenia do predchádzajúcich časových krokov. Môže byť však použitý na porovnanie s inými algoritmami pri vyhodnocovaní výsledkov.

Pri algoritme spätného šírenia chyby v čase musíme akokeby rozvinúť rekurentnú sieť do mnohovrstvovej doprednej siete (každý časový krok) a na takto rozvinutú sieť aplikovať algoritmus spätného šírenia chyby.

1.6 Meranie hĺbky pamäte samorganizujúcich sa máp

Ako trénovaciu množinu budem používať sekvenciu písmen abecedy (26 písmen). Vstupmi (trénovacie príklady) pre sieť budú zakódované jednotlivé písmená z trénovacej sekvencie. Písmená kódujem do 26 prvkového vektora, ktorého prvky budú nuly a jednotka (pre každé písmeno na inej pozícii). Každý neurón bude mať množinu v ktorej si bude pamätať pre aký vstup bol víťazom. Nebude si však ukladať iba konkrétne písmeno zo vstupu, ale k posledných písmen z trénovacej množiny (tzv. sliding window). Z toho si viem ďalej vytvoriť hitmapu, ktorá mi bude vizualizovať, na aké vstupy neuróny reagovali. Mierou hĺbky pamäte mapy bude potom vážený priemer dĺžky najdlhších spoločných podpostupností písmen v množinách jednotlivých neurónov. Dĺžku najdlhšej podpostupnosti budem určovať od konca sekvencií v množine. Priemer pamäťových hĺbok jednotlivých neurónov musí byť vážený, aby neuróny s väčším počtom víťazov mali vyššiu váhu ako neuróny s menším počtom víťazov. Po každej trénovacej epoche (prechode trénovacou množinou) budem vedieť určiť pamäťovú hĺbku mapy. Vďaka

tomu, že neuróny rekurentných sietí majú okrem normálnych váh aj kontextové váhy, ktoré uchovávajú informáciu z predchádzajúceho kroku, môže sa stať, že rovnaké písmeno zo vstupu bude mať rôzne víťazné neuróny počas tréovania.

Kapitola 2

Návrh riešenia

Kapitola 3

Implementácia

Kapitola 4

Experiment

Kapitola 5

Vyhodnotenie a výsledky experimentu

Kapitola 6

Záver

6.1 Limity a nedostatky riešenia

6.2 Možnosti ďalšej práce

Literatúra

- [1] Jeffrey L. Elman *Finding Structure in Time*. University of California, San Diego, 1990
- [2] H. Ritter and T. Kohonen *Self-Organizing Semantic Maps* Helsinki University of Technology, 1982
- [3] Thomas Voegtlin *Recursive self-organizing maps*, 2002
- [4] Marc Strickert, Barbara Hammer *Merge SOM for temporal data* Technical University of Clausthal, 2005