

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

POROVNANIE NIEKOLKÝCH TYPOV
REKURENTNÝCH SIETÍ Z HĽADISKA HĽBKY
PAMÄTE
DIPLOMOVÁ PRÁCA

2019
JAROSLAV IŠTOK

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

POROVNANIE NIEKOLKÝCH TYPOV
REKURENTNÝCH SIETÍ Z HĽADISKA HĽBKY
PAMÄTE
DIPLOMOVÁ PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: 2511 Aplikovaná informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: školiteľ

Bratislava, 2019
Jaroslav Ištók



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Jaroslav Ištók
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: aplikovaná informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Porovnanie niekoľkých typov rekurentných sietí z hľadiska hĺbky pamäte
Memory span in recurrent neural network types: a comparison

Anotácia: Cieľom práce je preskúmať a porovnať vlastnosti niektorých typov rekurentných samoorganizujúcich sa máp (MSOM, RecSOM a ich modifikácií) s Elmanovou jednoduchou rekurentnou sieťou (SRN), najmä z hľadiska hĺbky a kapacity pamäte. Práca zahŕňa implementáciu, výpočtové simulácie a analýzu vrátane preskúmania priestoru parametrov.

Literatúra: Elman, J. (1990). Finding structure in time. Cognitive Science, 14, 179-211.
Strickert, M. & Hammer, B. (2005). Merge SOM for temporal data. Neurocomputing, 64, 39-71.

Vedúci: doc. RNDr. Martin Takáč, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: prof. Ing. Igor Farkaš, Dr.
Dátum zadania: 05.10.2017

Dátum schválenia: 12.10.2017
prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Abstrakt

Abstrakt - obsah

Kľúčové slová: rekurentné neurónové siete, hĺbka pamäte

Abstract

Abstract

Keywords: neural net, machine learning, memory span

Obsah

1	Úvod	1
1.1	Motivácia	1
1.2	Úvod do neurónových sietí	2
1.2.1	Perceptrón	2
1.2.2	Viacvrstvová dopredná neurónová sieť	3
1.2.3	Trénovací algoritmus dopredných neurónových sietí	5
1.2.4	Rekurentné neurónové siete	6
1.2.5	Samoorganizujúce sa mapy	8
1.2.6	Trénovanie	8
1.2.7	Využitie SOM	11
1.2.8	Rekurentné modely	11
1.2.9	RecSOM	12
1.2.10	mSOM	13
2	Návrh riešenia	14
2.1	Meranie hĺbky pamäte samorganizujúcich sa máp	14
3	Implementácia	16
4	Experiment	17
5	Vyhodnotenie a výsledky experimentu	18
6	Záver	19
6.1	Limity a nedostatky riešenia	19
6.2	Možnosti ďalšej práce	19
	Bibliography	19

Zoznam obrázkov

1.1	Percetrón	2
1.2	Viacvrstvová dopredná neurónová sieť	3
1.3	Logistická sigmoida a Hyperbolický tangens	4
1.4	Rectified Linear Unit	5
1.5	Architektúra elmanovej siete	6
1.6	Rozvinutá Elmanova sieť	7
1.7	Neúplne rozvinutá sieť	10
1.8	Motýlí efekt	10
1.9	Pinch effect	11
1.10	Architektúra RecSOM	12
2.1	Hitmapa	14

Kapitola 1

Úvod

1.1 Motivácia

V strojovom učení nastávajú situácie, kedy potrebujeme predikovať výsledok nie len na základe aktuálneho vstupu, ale aj na základe historického kontextu. Kontextom sú väčšinou stavy modelu z minulých krokov. Príkladom takejto úlohy môže byť spracovanie tzv. časových radov či generovanie postupností. Predstavme si úlohu, v ktorej chceme model strojového učenia naučiť predikovať ďalšie písmeno v určitom slove. Ako príklad si môžeme zobrať slovo „Bratislava“. Trénovanie modelu strojového učenia bez využitia kontextu by mohlo prebiehať napríklad takto: Trénovaciou množinu by tvorili písmená daného slova kde očakávanou hodnotou pre nejaké písmeno by bolo ďalšie písmeno, ktoré za ním v slove nasleduje. Čiže pre písmeno „B“ poviem, že očakávame „r“ a takto pokračujem ďalej cez všetky písmená v slove.

Problém nastane pri druhom písmene „a“ v slove Bratislava. Pri prvom výskyte písmena „a“ sme modelu tvrdili, že očakávam písmeno „t“ a pri druhom výskyte písmena „a“ tvrdíme, že očakávame „v“. Tento prípad sa model, ktorý nevyužíva žiadny historický kontext, nevie naučiť, pretože nemá žiadnu pamäť (okno do minulosti).

V mojej práci sa budem zaoberať jedným z modelov strojového učenia, ktorý pracuje s kontextom: rekurentnými neurónovými sieťami viacerých typov a budem merať ich pamäťovú hĺbku. Pamäťová hĺbka neurónovej siete vo všeobecnosti vyjadruje to, s akým dlhým kontextom do minulosti dokáže pracovať.

Konkrétne pôjde o nasledujúcim tri typy rekurentných neurónových sietí:

- Elmanova sieť
- RecSOM
- MergeSOM

1.2 Úvod do neurónových sietí

1.2.1 Perceptrón

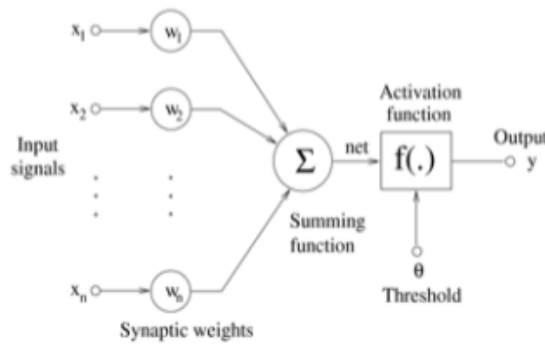
Je základným modelom neurónu, ktorý je používaný v neurónových sieťach.

Na vstupe každého perceptrónu je vektor vstupných hodnôt (vzor) \bar{x} pričom hodnoty sú reálne čísla alebo binárne hodnoty, v ktorých môže byť zakódované napríklad slovo alebo obrázok. Každý perceptrón má vektor synaptických váh \bar{w} .

Výstup perceptrón vyjadruje rovnica:

$$y = f\left(\sum_{j=1}^{n+1} w_j x_j\right) \quad x_{n+1} = -1 \quad (1.1)$$

Funkcia f sa nazýva aj aktivačná funkcia perceptrónu, ktorá môže byť spojitá alebo diskretná. Podľa toho, či je aktivačná funkcia spojitá alebo diskretná, rozlišujeme spojitý alebo diskretný perceptrón.



Obr. 1.1: Percetrón

Aktivačná funkcia diskretného perceptrónu je jednoduchá bipolárna funkcia, ktorá vráti +1 alebo 1.

$$f(net) = \text{sign}(net) = \begin{cases} 1 & \text{ak } net \geq 0 \\ -1 & \text{ak } net < 0 \end{cases}$$

Aktivačná funkcia spojitého perceptrónu je sigmoida.

$$f(net) = \frac{1}{1 + \exp^{-net}} \quad (1.2)$$

Vstupom do aktivačnej funkcie (net) je skalárny súčin vstupného vektora \bar{x} a váhového vektora perceptrónu \bar{w} .

$$net = \bar{x} \cdot \bar{w} \quad (1.3)$$

Trénovanie perceptrónu prebieha za pomoci učiteľa (angl. supervised learning). Pravidlo pre adaptáciu váh diskretného perceptrónu:

$$w_j(t+1) = w_j(t) + \alpha(d - y) \cdot x_j \quad (1.4)$$

Spojité perceptrón je trénovaný metódou najprudšieho spádu, pomocou ktorej minimalizujeme kvadratickú chybovú funkciu:

$$E(w) = \frac{1}{2} \sum_p (d^{(p)} - y^{(p)})^2 \quad (1.5)$$

Pravidlo pre adaptáciu váh v spojitom perceptróne:


$$w_j(t+1) = w_j(t) + \alpha(d^{(p)} - y^{(p)})f'(net)x_j = w_j(t) + \alpha\delta^{(p)}x_j \quad (1.6)$$

Kde p je index vzoru v trénovacej množine, y je skutočný výstup a d je požadovaný výstup.

Perceptrón je veľmi jednoduchým modelom. Nevie ním vyriešiť celú škálu úloh. Napríklad dokáže klasifikovať iba lineárne separovateľné dáta. Je však dokázané, že ak dáta sú lineárne separovateľné, trénovací algoritmus konverguje a teda vie dáta separovať. Perceptrón sa v strojovom učení niekedy označuje aj ako logistická regresia.

1.2.2 Viacvrstvá dopredná neurónová sieť

V našej práci sa budeme zaoberať Elmanovou rekurentnou neurónovou sieťou. [1] Najskôr však popíšeme základný viacvrstvový model neurónovej siete. Viacvrstvá dopredná neurónová sieť má jednu vstupnú vrstvu, jednu výstupnú vrstvu a minimálne jednu skrytú vrstvu. Jednotlivé vrstvy sú tvorené perceptrónmi a sú pospájané väzbami, ktoré majú váhy, resp. váhové vektory. Medzi neurónmi v tej istej vrstve nie sú žiadne spojenia.



Obr. 1.2: Viacvrstvá dopredná neurónová sieť

Trénovací algoritmus pomocou ktorého sa trénujú dopredné neurónové sa nazýva „spätne šírenie chyby“ (angl. backpropagation).

Aktivácie na neurónoch výstupnej vrstvy (výstup) môžeme popísať vzťahom:

$$y_i = f\left(\sum_{k=1}^{q+1} w_{ik} h_k\right) \quad (1.7)$$

Aktivácie na neurónoch skrytej vrstve môžeme popísať vzťahom:

$$h_k = f\left(\sum_{j=1}^{n+1} v_{kj} x_j\right) \quad (1.8)$$


Prahové hodnoty:

$$x_{n+1} = h_{q+1} = -1 \quad (1.9)$$

Aby dopredná neurónová sieť vedela pracovať aj s nelineárnymi problémami, musí byť aktivačná funkcia neurónov nejaká nelineárna diferencovateľná funkcia.


Najpoužívanéjšie aktivačné funkcie sú:

- Logistická sigmoida
- Hyperbolický tangens



Obr. 1.3: Logistická sigmoida a Hyperbolický tangens

- ReLU



Obr. 1.4: Rectified Linear Unit

Vzťahy pre aktualizáciu váh sú nasledovné:

Váhy medzi vstupnou a skrytou vrstvou

$$w_{ik}(t+1) = w_{ik}(t) + \alpha \delta_i h_k \quad \delta_i = (d_i - y_i) f'(net_i) \quad (1.10)$$

Váhy medzi skrytou a výstupnou vrstvou:

$$v_{kj}(t+1) = v_{kj}(t) + \alpha \delta_k x_j \quad \delta_k = \left(\sum_i w_{ik} \delta_i \right) f'(net_k) \quad (1.11)$$


1.2.3 Trénovací algoritmus dopredných neurónových sietí

1. zoberie sa vstup $x^{(p)}$ a vypočíta sa výstup $y^{(p)}$ (dopredný krok)
2. vypočíta sa chyba pomocou zvolenej chybovej funkcie
3. vypočítame hodnoty δ_i a δ_k (spätný krok)
4. upravíme váhy Δw_{ik} a Δv_{kj}
5. ak už boli použité všetky trénovacie príklady z trénovacej množiny pokračuj bodom 6. inak pokračuj bodom 1.
6. ak bolo dosiahnuté nejaké zastavovacie kritérium, potom skonči, inak prepermutovej vstupy a pokračuj bodom 1.

1.2.4 Rekurentné neurónové siete

Rekurentná neurónová sieť je akákoľvek neurónová sieť, ktorá obsahuje množinu neurónov v ktorých sa uchováva informácia o aktiváciách neurónov z predošlých krokov. Takéto neuróny nazývame aj rekurentné neuróny a tvoria vrstvu, ktorá sa nazýva kontextová vrstva. Týmto spôsobom je sieť rozšírená o vnútornú pamäť.

V mojej práci budem skúmať vlastnosti a pamäťovú hĺbku rekurentnej siete s Elmanovou architektúrou, ktorá je znázornená na nasledujúcom diagrame.



Obr. 1.5: Architektúra elmanovej siete

Dvojité šípky reprezentujú spojenia neurónov medzi vrstvami. Neuróny v tej istej vrstve nie sú, podobne ako v nerekurentnej, teda doprednej, sieti, medzi sebou prepojené. Spojenia znázornené dvojitou šípkou majú váhy, ktoré sú upravované počas tréningu. Jednoduché šípky reprezentujú rekurentné spojenia. Tieto majú nemennú váhu s hodnotou 1. Tieto spojenia slúžia na odpamätanie aktivácii rekurentných neurónov.

Využitie rekurentných neurónových sietí:

- Klasifikácia s časovým kontextom

Príkladom úlohy môže byť napríklad určiť, či určitá postupnosť vstupov patrí do nejakej triedy. Praktickým problémom môže byť zistiť či postupnosť signálov z určitého zariadenia signalizuje poruchu zariadenia alebo nie.


- Predikcie

Príkladom môže byť napríklad predikcia nasledujúceho člena postupnosti.

- Generovanie postupnosti

Podobne ako predikcie, ale nepredikujeme iba ďalšiu hodnotu postupnosti, ale celé pokračovanie. Je to komplexnejšia úloha. Napríklad 23123123123123123123 .. pokračovaním by bolo 123123123... Reálne úlohy sú komplexnejšie.

Trénovací algoritmus, ktorým sa trénujú rekurentné neurónové siete je spätné šírenie chyby v čase (angl. backpropagation through time). Pri použití tohto algoritmu sa sieť rozvíja v čase, t.j. rozvinutá sieť má toľko skrytých vrstiev, koľko je vstupov T vo vstupnej postupnosti. Takáto sieť sa potom trénuje podobne ako klasická nerekurentná dopredná sieť s T skrytými vrstvami pomocou jednoduchého spätného šírenia chyby. Aktivity neurónov kontextovej vrstvy sú na začiatku každého cyklu trénovania nastavené na hodnotu 0.5.



Obr. 1.6: Rozvinutá Elmanova sieť

Výstup takejto siete počítame pomocou vzťahu:

$$o_k^{(T+1)} = f\left(\sum_{j=1}^J m_{kj}^{T+1} y_j^{T+1}\right) \quad (1.12)$$

$$y_j^{t+1} = f\left(\sum_{i=1}^J w_{ji}^t y_i^t + \sum_{i=1}^I v_{ji}^t x_i^t\right) \quad (1.13)$$

Chybová funkcia v čase $T + 1$

$$E(T + 1) = \frac{1}{2} \sum_{k=1}^K (d_k^{(T+1)} - o_k^{(T+1)})^2 \quad (1.14)$$

Zmena váh medzi vstupnou a výstupnou vrstvou:

$$\Delta m_{kj}^{T+1} = -\alpha \frac{\partial E(T + 1)}{\partial m_{kj}} = \alpha \delta_k^{T+1} y_j^{T+1} \quad (1.15)$$

$$\delta_k^{T+1} = (d_k^{T+1} - o_k^{T+1}) f'(net_k^{T+1}) \quad (1.16)$$

Váhy medzi rozvinutými vrstvami a medzi vstupom a rozvinutými vrstvami sa upravujú pomocou vzťahov:

$$\Delta w_{hj}^{T+1} = \frac{\sum_{t=1}^T \Delta w_{hj}^t}{T} \quad (1.17)$$

$$\Delta w_{ji}^{T+1} = \frac{\sum_{t=1}^T \Delta w_{ji}^t}{T} \quad (1.18)$$

1.2.5 Samoorganizujúce sa mapy

Ďalším typom rekurentných neurónových sietí, ktorých pamäťovú hĺbku budeme skúmať v našej práci, sú rekurentné samoorganizujúce sa mapy, ktoré sú rozšírením základnej nerekurentnej verzie samoorganizujúcich sa máp (ďalej iba SOM). Preto najskôr popíšem základný nerekurentný model SOM.

SOM je typ neurónovej siete, v ktorej sú jednotlivé neuróny usporiadané do (väčšinou) dvojrozmernej štvorcovej mriežky. Samoorganizujúce sa mapy (ďalej iba SOM) sú tréňované bez učiteľa, čiže váhy jednotlivých neurónov sú upravované iba na základe dát z tréňovacej množiny. Čo je zaujímavé na spôsobe tréňovania SOM je, že je veľmi podobný učeniu neurónov v mozgovej kôre živočíchov. Je to biologicky inšpirovaný model. Špeciálnou vlastnosťou SOM je, že po natrénovaní zobrazí tréňovaciu množinu so zachovanou topológiou. To znamená, že blízke (podobné) vstupy aktivujú blízke neuróny v sieti. Vzdialenosť dvoch neurónov je ich euklidovská vzdialenosť v mriežke. Takéto topologické zobrazenie dát sa vyskytuje aj v biologických neurónových sieťach.

1.2.6 Tréňovanie

Proces tréňovania SOM je zložený z dvoch častí:

- hľadanie víťaza
- adaptácia váh neurónov

Na začiatku su váhy medzi vstupom a neurónmi v mriežke inicializujú na náhodné hodnoty z určitého intervalu. V každom kroku tréňovania nájdeme najskôr víťazný neurón pre daný vstup. Postupne počítame euklidovské vzdialenosti vstupu od váhového vektora jednotlivých neurónov. Víťazom je neurón, ktorý je najbližšie k vstupu (má najkratšiu vzdialenosť).

$$i^* = \operatorname{argmin}_i ||x - w_i|| \quad (1.19)$$

Druhým krokom je adaptácia váh víťazného neurónu a jeho okolia. Pravidlo pre zmenu váh neurónov:

$$w_i(t+1) = w_i(t) + \alpha(t)h(i^*, i)([x(t) - w_i(t)]) \quad (1.20)$$

Váhové vektory víťazného neurónu a jeho topologických susedov sa posúvajú smerom k aktuálnemu vstupu. $\alpha(t)$ predstavuje rýchlosť učenia, ktorá môže klesať v čase alebo môže zostať konštantná. Na funkcii, ktorá je použitá pre α , v praxi veľmi nezáleží, mala by to byť nejaká monotónne klesajúca funkcia (napríklad exponenciálna funkcia). $h(i^*, i)$ je funkcia okolia (tzv. excitačná funkcia), ktorá definuje koľko neurónov v okolí

vítaza bude tréovaných a do akej miery. Inými slovami, excitačná funkcia definuje rozsah kooperácie medzi neurónmi. Používajú sa najčastejšie 2 typy okolia:

- pravouhlé(štvorcové) okolie

$$N(i^*, i) = \begin{cases} 1 & \text{ak } d_M(i^*, i) \leq \lambda(t) \\ 0 & \text{inak} \end{cases}$$

$d_M(i^*, i)$ je Manhattanovská vzdialenosť (L1 norma) medzi neurónmi v mriežke mapy. Kohonen zistil, že najlepšie výsledky sú dosiahnuté, keď sa veľkosť okolia s časom postupne znižuje.

- gaussovské okolie

$$N(i^*, i) = \exp^{-\frac{d_E^2(i^*, i)}{\lambda^2(t)}} \quad (1.21)$$

$d_E(i^*, i)$ je euklidovská vzdialenosť (L2 norma) neurónov v mriežke. Funkcia $\lambda^2(t)$ sa s časom postupne znižuje až k nule. Táto funkcia slúži na zmenšovanie okolia víťazného neurónu počas tréovania, čím sa zabezpečí ukončenie učenia.

$[x(t) - w_i(t)]$ je euklidovská vzdialenosť medzi vstupným vektorom a váhovým vektorom.

Na vyhodnocovanie tréovania SOM používame kvantizačnú chybu. Je to euklidovská vzdialenosť vstupu od váh víťazného neurónu. Po každej epoche učenia vieme určiť celkovú kvantizačnú chybu siete pre danú tréovaciu množinu. Pre každý príklad z tréovacej množiny vypočítame kvantizačnú chybu a spriemerujeme. Táto by mala po každej epoche učenia (po natréovaní a adaptácii váh na celej tréovacej množine) postupne klesať.


Pri učení rozlišujeme všeobecne dve fázy:

- usporiadavanie - s časom klesá veľkosť okolia víťazných neurónov
- doladovanie - veľkosť okolia sa zafixuje na nejakej malej hodnote až pokým učenie neskončí.

Kohonen odhadol na základe pokusov, že počet iterácií tréovania, by mal byť rádovo 500-násobok počtu neurónov v sieti. Rovnako sa pozorovaním zistilo, že na fázu doladenia je lepšie ponechať viac času ako na fázu usporiadavania.


Počas tréovania SOM môžu nastať špeciálne situácie:

- Sieť je neúplne rozvinutá - príliš rýchle zmenšovanie rýchlosti učenia α




Obr. 1.7: Neúplne rozvinutá sieť

- Motýlí efekt - príliš rýchle zmenšovanie okolia λ



Obr. 1.8: Motýlí efekt

- Pinch efekt - príliš pomalé zmenšovanie okolia λ



Obr. 1.9: Pinch effect

1.2.7 Využitie SOM

- SOM môžeme využiť na mapovanie viacrozmerných dát do 2D - môžeme ju použiť na redukciu dimenzie dát.
- SOM je aj vektorovým kvantizátorom. Pri vektorovej kvantizácii nahrádzame množinu vektorov vstupných dát menšou množinou vektorov (nazývaných aj prototypy). V SOM sú prototypmi váhové vektory. Toto je možné využiť napríklad na kompresiu dát. Vďaka vektorovej kvantizácii stačí uchovať iba množinu prototypov a informáciu o tom, ktorý vstupný vektor patrí ku ktorému prototypu (centru). Ku každému centru sa potom priradí množina vstupných vektorov, ktoré ku nemu majú bližšie ako ku akémukoľvek inému centru (používa sa euklidovská vzdialenosť). Vektorovou kvantizáciou teda rozdelíme vstupný priestor na disjunktné oblasti, ktoré tvoria tzv. Voronoiho mozaiku.

1.2.8 Rekurentné modely

Rekurentné samoorganizujúce sa mapy sú modifikáciou nerekurentnej SOM. Rozdiel oproti nerekurentnej verzii je v tom, že vstupy sú porovnávané nielen s váhovým vektorom jednotlivých neurónov, ale aj s kontextom. Rôzne verzie rekurentných SOM sa líšia iba v type kontextu, ktorý je v nich použitý. V kontexte je spravidla uložený stav siete alebo časti siete z minulého časového kroku.


V mojej práci budem porovnávať 2 základné typy rekurentných SOM.

- Recursive SOM (RecSOM): Pri RecSOM je kontextom celá kópia aktivácií neurónov z minulého kroku.

- Merge SOM (mSOM): Pri mSOM sú kontextom vlastnosti víťazného neurónu z predchádzajúceho kroku učenia.

1.2.9 RecSOM

Pri RecSom je SOM algoritmus použitý rekurzívne na vstupný vektor $x(t)$ a tiež reprezentáciu mapy z minulého kroku $y(t-1)$. [6]



Obr. 1.10: Architektúra RecSOM

V RecSOM je každý vstup asociovaný k stavom z predchádzajúcich krokov a preto každý neurón reaguje na sekvenciu vstupov. Prerušované čiary predstavujú trénovateľné spojenia.

Každý neurón má 2 váhové vektory. Váhový vektor w_i , ktorý je porovnávaný so vstupným vektorom $x(t)$ a vektor kontextových váh c_i , ktorý je porovnávaný s kontextom z predchádzajúceho kroku $y(t-1)$. Keďže chceme aby boli dopredné a spätné spojenia v RecSOM homogénne, celkovú chybu určíme ako váhovaný súčet druhých mocnín kvantizačných chýb oboch prípadov. Chyba je vlastne váhovaný súčet euklidovských vzdialeností vstupu od váhového vektoru a kontextu z predchádzajúceho kroku od kontextových váh.

N je počet neurónov v sieti (pretože kontextom je kópia celej mapy)

$$d_i = \alpha \cdot \|x(t) - w_i\|^2 + b \cdot \|y(t-1) - c_i\|^2 \quad c \in R^N \quad (1.22)$$

α a β sú parametre, ktoré určujú akú váhu pri trénovaní bude mať kontext a akú váhu bude mať aktuálny krok.

Kontextom je kópia aktivácií všetkých neurónov z predchádzajúceho kroku.

$$y(t) = [y_1(t-1), \dots, y_N(t-1)] \quad c, r \in R^N \quad (1.23)$$

Hodnota aktivácie pre určitý neurón je vyjadrená vzťahom:

$$y_i = \exp(-d_i) \quad (1.24)$$

Pravidlo pre zmenu váh neurónov (podobné ako pri nerekurentnej SOM):

$$w_i(t+1) = w_i(t) + \alpha(t)h(i^*, i)[x(t) - w_i(t)] \quad (1.25)$$

Pre zmenu kontextových váh, platí to isté pravidlo ako pre normálne váhy, iba je aplikované na kontextové vektory:

$$c_i(t+1) = c_i(t) + \alpha(t)h(i^*, i)[y(t-1) - c_i(t)] \quad (1.26)$$

Pri RecSom majú kontext aj kontextové váhy veľkú dimenziu (rovnú počtu neurónov v sieti), čo môže spomaľovať proces tréovania. Výhodou môže byť, že kontext RecSOM obsahuje veľa informácií a teda môže mať v niektorých prípadoch lepšie vlastnosti.

1.2.10 mSOM

mSOM je podobná recSOM, líši sa v reprezentácii kontextu. [5]

Chybu (vzdialenosť vstupu od neurónu) vyjadríme vzťahom (podobne ako pri recSOM), d je dimenzia vstupov:

$$d = \alpha \cdot \|s(t) - w_i\|^2 + \beta \cdot \|r(t) - c_i\|^2 \quad x, c \in R^d \quad (1.27)$$

Kontextom pri mSOM nie je kópia aktivácií neurónov z predchádzajúceho kroku, ako je tomu pri RecSom. Kontextom pri mSOM je zlúčenie (lineárna kombinácia) vlastností víťaza z predchádzajúceho kroku. (Odtiaľ je odvodený názov - „zlučovacia samoorganizujúca sa mapa“ - Merge SOM). Kontext mSOM vyjadríme vzťahom:

$$y(t) = \beta \cdot w_{i^*}(t-1) + (1 - \beta) \cdot y_{i^*}(t-1) \quad (1.28)$$

β je zlučovací parameter, ktorý určuje váhu kombinovaných vlastností víťazného neurónu z predchádzajúceho kroku. Typická hodnota tohto parametra počas tréovania je $\beta = 0.5$, čiže taká, aby obe zložky mali približne rovnakú váhu. Kontextom pri mSOM je teda lineárna kombinácia váhového vektora a kontextového vektora víťazného neurónu z predchádzajúceho kroku. Pravidlá pre zmenu váh a kontextových váh zostávajú rovnaké ako pri RecSom, resp. SOM. Líšia sa iba v kontexte.

$$w_i(t+1) = w_i(t) + \alpha(t)h(i^*, i)[s(t) - w_i(t)] \quad (1.29)$$

Pravidlo pre zmenu kontextových váh:

$$c_i(t+1) = c_i(t) + \alpha(t)h(i^*, i)[y(t-1) - c_i(t)] \quad (1.30)$$


Kontext pri mSOM obsahuje odlišné informácie ako pri RecSom. Na rozdiel od recSom, kde kontext tvorí vektor aktivít neurónov z predchádzajúceho kroku, pri mSOM je kontext tvorený iba lineárnou kombináciou vlastností víťazného neurónu z minulého kroku. Má však menšiu dimenziu (dimenziu vstupu), vďaka čomu je tréovanie mSOM rýchlejšie a teda je možné použiť viacrozmerne mapy a viac epoch tréovania. Rozdielne typy kontextov a ich vplyv na pamäťovú hĺbku rekurentných sietí je jedným z cieľov mojej diplomovej práce.

Kapitola 2

Návrh riešenia

2.1 Meranie hĺbky pamäte samorganizujúcich sa máp

Ako trénovaciu množinu budem používať sekvenciu písmen abecedy (26 písmen). Vstupmi (trénovacie príklady) pre sieť budú zakódované jednotlivé písmená z trénovacej sekvencie. Písmená kódujem do 26 prvkového vektora, ktorého prvky budú nuly a jednotka (pre každé písmeno na inej pozícii). Každý neurón bude mať množinu v ktorej si bude pamätať pre aký vstup bol víťazom. Nebude si však ukladať iba konkrétne písmeno zo vstupu, ale k posledných písmen z trénovacej množiny (tzv. sliding window). Z toho si viem ďalej vytvoriť hitmapu, ktorá mi bude vizualizovať, na aké vstupy neuróny reagovali.



Obr. 2.1: Hitmapa

Mierou hĺbky pamäte mapy bude potom vážený priemer dĺžky najdlhších spoločných podpostupností písmen v množinách jednotlivých neurónov. Dĺžku najdlhšej podpostupnosti budem určovať od konca sekvencií v množine. Priemer pamäťových hĺbok jednotlivých neurónov musí byť vážený, aby neuróny s väčším počtom víťazov mali

vyššiu váhu ako neuróny s menším počtom víťazov. Po každej tréningovej epoche (prechode tréningovou množinou) budem vedieť určiť pamäťovú hĺbku mapy. Vďaka tomu, že neuróny rekurentných sietí majú okrem normálnych váh aj kontextové váhy, ktoré uchovávajú informáciu z predchádzajúceho kroku, môže sa stať, že rovnaké písmeno zo vstupu bude mať rôzne víťazné neuróny počas tréningovania.

Kapitola 3

Implementácia

Kapitola 4

Experiment

Kapitola 5

Vyhodnotenie a výsledky experimentu

Kapitola 6

Záver

6.1 Limity a nedostatky riešenia

6.2 Možnosti ďalšej práce

Bibliografia

- [1] Jeffrey L. Elman. “Finding structure in time”. In: *COGNITIVE SCIENCE* 14.2 (1990), s. 179–211.
- [2] Jiang Guo. “Backpropagation through time”. In: *Unpubl. ms., Harbin Institute of Technology* (2013).
- [3] Teuvo Kohonen. “Essentials of the Self-organizing Map”. In: *Neural Netw.* 37 (jan. 2013), s. 52–65. ISSN: 0893-6080. DOI: 10.1016/j.neunet.2012.09.018. URL: <http://dx.doi.org/10.1016/j.neunet.2012.09.018>.
- [4] H. Ritter a T. Kohonen. “Self-organizing Semantic Maps”. In: *Biol. Cybern.* 61.4 (aug. 1989), s. 241–254. ISSN: 0340-1200. DOI: 10.1007/BF00203171. URL: <http://dx.doi.org/10.1007/BF00203171>.
- [5] Marc Strickert a Barbara Hammer. “Merge SOM for temporal data”. In: *Neurocomputing* 64 (2005), s. 39–71.
- [6] Thomas Voegtlin. “Recursive Self-organizing Maps”. In: *Neural Netw.* 15.8-9 (okt. 2002), s. 979–991. ISSN: 0893-6080. DOI: 10.1016/S0893-6080(02)00072-2. URL: [http://dx.doi.org/10.1016/S0893-6080\(02\)00072-2](http://dx.doi.org/10.1016/S0893-6080(02)00072-2).