

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

POROVNANIE NIEKOĽKÝCH TYPOV
REKURENTNÝCH SIETÍ Z HĽADISKA HĽBKY
PAMÄTE
DIPLOMOVÁ PRÁCA

2019

JAROSLAV IŠTOK

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

POROVNANIE NIEKOĽKÝCH TYPOV
REKURENTNÝCH SIETÍ Z HĽADISKA HĽBKY
PAMÄTE
DIPLOMOVÁ PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: 2511 Aplikovaná informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: školiteľ

Bratislava, 2019
Jaroslav Ištók



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Jaroslav Ištók
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: aplikovaná informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Porovnanie niekoľkých typov rekurentných sietí z hľadiska hĺbky pamäte
Memory span in recurrent neural network types: a comparison

Anotácia: Cieľom práce je preskúmať a porovnať vlastnosti niektorých typov rekurentných samoorganizujúcich sa máp (MSOM, RecSOM a ich modifikácií) s Elmanovou jednoduchou rekurentnou sieťou (SRN), najmä z hľadiska hĺbky a kapacity pamäte. Práca zahŕňa implementáciu, výpočtové simulácie a analýzu vrátane preskúmania priestoru parametrov.

Literatúra: Elman, J. (1990). Finding structure in time. Cognitive Science, 14, 179-211.
Strickert, M. & Hammer, B. (2005). Merge SOM for temporal data. Neurocomputing, 64, 39-71.

Vedúci: doc. RNDr. Martin Takáč, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: prof. Ing. Igor Farkaš, Dr.
Dátum zadania: 05.10.2017

Dátum schválenia: 12.10.2017
prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Abstrakt

Abstrakt - obsah

Kľúčové slová: rekurentné neurónové siete, hĺbka pamäte

Abstract

Abstract

Keywords: neural net, machine learning, memory span

Obsah

1	Úvod	1
1.1	Motivácia	1
1.2	Prehľad literatúry a úvod do problematiky	1
1.2.1	Samoorganizujúca sa mapy	1
1.2.2	Trénovanie	1
1.3	Štruktúra ďalšej práce	2
1.4	Typy neurónových sietí	2
1.5	Elmanova sieť a backpropagácia v čase	2
1.6	Meranie hĺbky pamäte samorganizujúcich sa máp	3
2	Návrh riešenia	4
3	Implementácia	5
4	Experiment	6
5	Vyhodnotenie a výsledky experimentu	7
6	Záver	8
6.1	Limity a nedostatky riešenia	8
6.2	Možnosti ďalšej práce	8
	Bibliography	8

Zoznam obrázkov

Kapitola 1

Úvod

1.1 Motivácia

V mojej diplomovej práci budem skúmať hĺbku pamäte rôznych typov neurónových sietí.

1.2 Prehľad literatúry a úvod do problematiky

1.2.1 Samoorganizujúca sa mapy

Je to typ neurónovej siete, v ktorej sú jednotlivé neuróny usporiadané do štvorcovej mriežky. Samorganizujúce sa mapy (ďalej iba SOM) sú trénované bez učiteľa, čiže váhy jednotlivých neurónov sú upravované iba na základe trénovacej množiny. Čo je zaujímavé na spôsobe tréningu SOM je, že je veľmi podobný učeniu neurónov v mozgovej kôre živočíchov.

Špeciálnou vlastnosťou SOM je, že po natrénovaní zobrazí trénovaciu množinu so zachovanou topológiou. To znamená, že blízke (podobné) vstupy aktivujú blízke neuróny v sieti. Vzdialenosť dvoch neurónov je ich euklidovská vzdialenosť v mriežke. Toto topologické zobrazenie dát sa vyskytuje aj v biologických neurónových sieťach.

1.2.2 Trénovanie

Proces tréningu SOM je zložený z dvoch častí:

- hľadanie víťaza
- adaptácia váh neurónov

V každom kroku tréningu nájdeme najskôr víťazný neurón pre daný vstup. Postupne počítam euklidovské vzdialenosti vstupu od váhového vektora jednotlivých neurónov. Víťazom je neurón, ktorý je najbližšie k vstupu (má najkratšiu vzdialenosť).

$$i^* = \operatorname{argmin}_i ||x - w_i|| \quad (1.1)$$

Druhým krokom je adaptácia váh víťazného neurónu a jeho okolia. Pravidlo pre zmenu váh neurónov:

$$w_i(t+1) = w_i(t) + \alpha(t)h(i^*, i)([x(t) - w_i(t)] \quad (1.2)$$

Váhové vektory víťazného neurónu a jeho topologických susedov sa posúvajú smerom k aktuálnemu vstupu. $\alpha(t)$ predstavuje rýchlosť učenia, ktorá sa môže klesať v čase alebo môže zostať konštantná. $h(i^*, i)$ je funkcia okolia (tzv. excitačná funkcia), ktorá definuje koľko neurónov v okolí víťaza bude tréňovaných a do akej miery. Inými slovami, excitačná funkcia definuje rozsah kooperácie medzi neurónmi. Používajú sa najčastejšie 2 typy okolia:

- pravouhlé okolie
- gaussovské okolie

1.3 Štruktúra ďalšej práce

1.4 Typy neurónových sietí

- elmanova sieť
- recSOM
- mergeSOM

1.5 Elmanova sieť a backpropagácia v čase

Jednoduchú Elmanovu sieť nie je vhodné trénovať pomocou jednoduchého algoritmu spätného šírenia chyby, pretože neberie do úvahy spätné šírenie chybového signálu cez rekurentné prepojenia do predchádzajúcich časových krokov. Môže byť však použitý na porovnanie s inými algoritmami pri vyhodnocovaní výsledkov.

Pri algoritme spätného šírenia chyby v čase musíme ako keby rozvinúť rekurentnú sieť do mnohvrstvovej doprednej siete (každý časový krok) a na takto rozvinutú sieť aplikovať algoritmus spätného šírenia chyby.

1.6 Meranie hĺbky pamäte samorganizujúcich sa máp

Ako trénovaciu množinu budem používať sekvenciu písmen abecedy (26 písmen). Vstupmi (trénovacie príklady) pre sieť budú zakódované jednotlivé písmená z trénovacej sekvencie. Písmená kódujem do 26 prvkového vektora, ktorého prvky budú nuly a jednotka (pre každé písmeno na inej pozícii). Každý neurón bude mať množinu v ktorej si bude pamätať pre aký vstup bol víťazom. Nebude si však ukladať iba konkrétne písmeno zo vstupu, ale k posledných písmen z trénovacej množiny (tzv. sliding window). Z toho si viem ďalej vytvoriť hitmapu, ktorá mi bude vizualizovať, na aké vstupy neuróny reagovali. Mierou hĺbky pamäte mapy bude potom vážený priemer dĺžky najdlhších spoločných podpostupností písmen v množinách jednotlivých neurónov. Dĺžku najdlhšej podpostupnosti budem určovať od konca sekvencií v množine. Priemer pamäťových hĺbok jednotlivých neurónov musí byť vážený, aby neuróny s väčším počtom víťazov mali vyššiu váhu ako neuróny s menším počtom víťazov. Po každej trénovacej epoche (prechode trénovacou množinou) budem vedieť určiť pamäťovú hĺbku mapy. Vďaka tomu, že neuróny rekurentných sietí majú okrem normálnych váh aj kontextové váhy, ktoré uchovávajú informáciu z predchádzajúceho kroku, môže sa stať, že rovnaké písmeno zo vstupu bude mať rôzne víťazné neuróny počas trénovania.

Kapitola 2

Návrh riešenia

Kapitola 3

Implementácia

Kapitola 4

Experiment

Kapitola 5

Vyhodnotenie a výsledky experimentu

Kapitola 6

Záver

6.1 Limity a nedostatky riešenia

6.2 Možnosti ďalšej práce

Literatúra

- [1] Jeffrey L. Elman *Finding Structure in Time*. University of California, San Diego, 1990
- [2] H. Ritter and T. Kohonen *Self-Organizing Semantic Maps* Helsinki University of Technology, 1982
- [3] Thomas Voegtlin *Recursive self-organizing maps*, 2002
- [4] Marc Strickert, Barbara Hammer *Merge SOM for temporal data* Technical University of Clausthal, 2005