

COMENIUS UNIVERSITY IN BRATISLAVA  
FACULTY OF MATHEMATICS, PHYSICS AND INFORMATICS

MEMORY SPAN IN DIFFERENT RECURRENT  
NEURAL NETWORK TYPES  
MASTER THESIS

2019  
JAROSLAV IŠTOK

COMENIUS UNIVERSITY IN BRATISLAVA  
FACULTY OF MATHEMATICS, PHYSICS AND INFORMATICS

MEMORY SPAN IN DIFFERENT RECURRENT  
NEURAL NETWORK TYPES  
MASTER THESIS

Study programmes :	Applied Informatics
Branch of study:	2511 Applied Informatics
Educational department:	Department of Applied Informatics
Advisor:	školitel

Bratislava, 2019  
Jaroslav Ištók



Univerzita Komenského v Bratislave  
Fakulta matematiky, fyziky a informatiky

## ZADANIE ZÁVEREČNEJ PRÁCE

**Meno a priezvisko študenta:** Bc. Jaroslav Ištók  
**Študijný program:** aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)  
**Študijný odbor:** aplikovaná informatika  
**Typ záverečnej práce:** diplomová  
**Jazyk záverečnej práce:** slovenský  
**Sekundárny jazyk:** anglický

**Názov:** Porovnanie niekoľkých typov rekurentných sietí z hľadiska hĺbky pamäte  
*Memory span in recurrent neural network types: a comparison*

**Anotácia:** Cieľom práce je preskúmať a porovnať vlastnosti niektorých typov rekurentných samoorganizujúcich sa máp (MSOM, RecSOM a ich modifikácií) s Elmanovou jednoduchou rekurentnou sieťou (SRN), najmä z hľadiska hĺbky a kapacity pamäte. Práca zahŕňa implementáciu, výpočtové simulácie a analýzu vrátane preskúmania priestoru parametrov.

**Literatúra:** Elman, J. (1990). Finding structure in time. Cognitive Science, 14, 179-211.  
Strickert, M. & Hammer, B. (2005). Merge SOM for temporal data. Neurocomputing, 64, 39-71.

**Vedúci:** doc. RNDr. Martin Takáč, PhD.  
**Katedra:** FMFI.KAI - Katedra aplikovanej informatiky  
**Vedúci katedry:** prof. Ing. Igor Farkaš, Dr.  
**Dátum zadania:** 05.10.2017

**Dátum schválenia:** 12.10.2017  
prof. RNDr. Roman Ďurikovič, PhD.  
garant študijného programu

.....  
študent

.....  
vedúci práce

**Acknowledgment:**

# Abstrakt

Abstrakt - obsah

**Klíčové slová:** klíčové slová

# Abstract

Abstract

**Keywords:** Neural Net, Machine Learning, Prediction

# Obsah

<b>1</b>	<b>Uvod</b>	<b>1</b>
1.1	Typy neurónových sietí . . . . .	1
1.2	Meranie hĺbky pamäte samorganizujúcich sa máp . . . . .	1
<b>2</b>	<b>Navrh riesenia</b>	<b>3</b>
<b>3</b>	<b>Implementacia</b>	<b>4</b>
<b>4</b>	<b>Experiment</b>	<b>5</b>
<b>5</b>	<b>Vyhodnotenie</b>	<b>6</b>
<b>6</b>	<b>Zaver</b>	<b>7</b>
6.0.1	Kapitola . . . . .	7
	<b>Bibliography</b>	<b>7</b>

# Zoznam obrázkov



# Kapitola 1

## Uvod

### 1.1 Typy neurónových sietí

- elmanova sieť
- recSOM
- mergeSOM

### 1.2 Meranie hĺbky pamäte samorganizujúcich sa máp

Ako trénovaciu množinu budem používať sekvenciu písmen abecedy (26 písmen). Vstupmi (trénovacie príklady) pre sieť budú zakódované jednotlivé písmená z trénovacej sekvencie. Písmená kódujem do 26 prvkového vektora, ktorého prvky budú nuly a jednotka (pre každé písmeno na inej pozícii). Každý neurón bude mať množinu v ktorej si bude pamätať pre aký vstup bol víťazom. Nebude si však ukladať iba konkrétne písmeno zo vstupu, ale  $k$  posledných písmen z trénovacej množiny (tzv. sliding window). Z toho si viem ďalej vytvoriť hitmapu, ktorá mi bude vizualizovať, na aké vstupy neuróny reagovali. Mierou hĺbky pamäte mapy bude potom vážený priemer dĺžky najdlhších spoločných podpostupností písmen v množinách jednotlivých neurónov. Dĺžku najdlhšej podpostupnosti budem určovať od konca sekvencií v množine. Priemer pamäťových hĺbok jednotlivých neurónov musí byť vážený, aby neuróny s väčším počtom víťazov mali vyššiu váhu ako neuróny s menším počtom víťazov. Po každej trénovacej epoche (prechode trénovacou množinou) budem vedieť určiť pamäťovú hĺbku mapy. Vďaka tomu, že neuróny rekurentných sietí majú okrem normálnych váh aj kontextové váhy, ktoré uchovávajú informáciu z predchádzajúceho kroku, môže sa stať, že rovnaké písmeno zo vstupu bude mať rôzne víťazné neuróny počas trénovania.

## Kapitola 2

### Navrh riesenia

# Kapitola 3

## Implementacia

# Kapitola 4

## Experiment

## Kapitola 5

### Vyhodnotenie

# Kapitola 6

## Zaver

### 6.0.1 Kapitola

# Literatúra

- [1] Jeffrey L. Elman *Finding Structure in Time*. University of California, San Diego, 1990
- [2] H. Ritter and T. Kohonen *Self-Organizing Semantic Maps* Helsinki University of Technology, 1982
- [3] Thomas Voegtlin *Recursive self-organizing maps*, 2002
- [4] Marc Strickert, Barbara Hammer *Merge SOM for temporal data* Technical University of Clausthal, 2005